

## machine learning



## machine learning - apprendimento automatico

- dare ai computer la capacità di *apprendere dai dati* senza ricevere regole esplicite da un essere umano (programmatore)
  - imparare dai dati senza essere programmati
  - computer addestrato non programmato
- algoritmi classici
  - è l'uomo a *specificare* il modo in cui individuare la *soluzione migliore* (algoritmo risolutivo)
  - il computer (programma) raggiunge la soluzione (esegue l'algoritmoprogramma) in modo più veloce ed efficiente di un essere umano



## machine learning - algoritmi

- capacità di un algoritmo
  - di *prendere decisioni* sulla base di una base di conoscenza (knowledge-base)
  - di *apprendere nuove informazioni* sulla base dell'esperienza (decisioni prese precedentemente)
  - al modello *non* viene fornita la *soluzione* migliore
  - riceve vari *esempi* del problema e gli viene chiesto di *decidere* qual è la soluzione migliore



## machine learning - tipologie

- tre tipologie fondamentali
  - *supervised learning* (apprendimento supervisionato)
  - unsupervised learning (apprendimento non supervisionato)
  - semi-supervised learning (apprendimento semi-supervisionato)





# supervised learning

 $apprendimento\ supervisionato$ 



## supervised learning

- apprendimento *supervisionato*
- tecnica di apprendimento automatico che ha l'obiettivo di *istruire* un sistema
- per elaborare automaticamente *previsioni* sui valori di *uscita*
- rispetto ad un *input*
- sulla base di una serie di *esempi* ideali
- esempi *forniti* inizialmente e costituiti da *coppie* di input e di output



/11/11/11/11/11/11 ファチ17ァフフフフフフフ)フ 



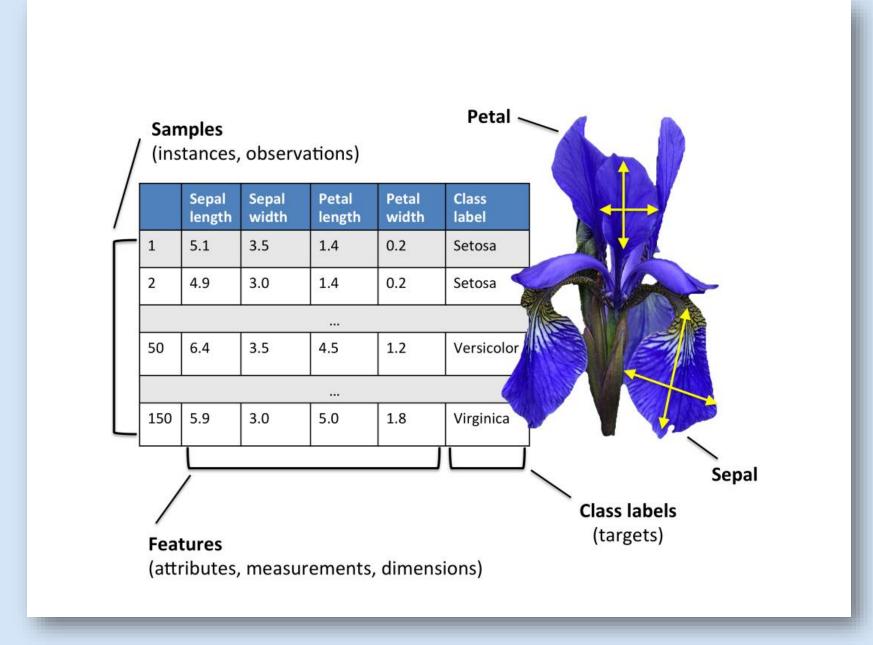


## classico esempio: iris dataset

- il dataset *Iris* è un dataset *multivariato* (*più features per ogni occorrenza*) introdotto da Ronald Fisher nel 1936
- consiste in *150 istanze* di Iris
- classificate secondo tre specie: Iris setosa, Iris virginica e Iris versicolor
- le variabili (features) sono
  - lunghezza del sepalo
  - · larghezza del sepalo
  - lunghezza del petalo
  - · larghezza del petalo









## supervised learning - training set - test set

#### training set

- insieme di dati di *addestramento*
- contiene informazioni etichettate (*labeled*) per permettere all'algoritmo di trovare il modo migliore per indovinare il maggior numero di casi

#### labeling

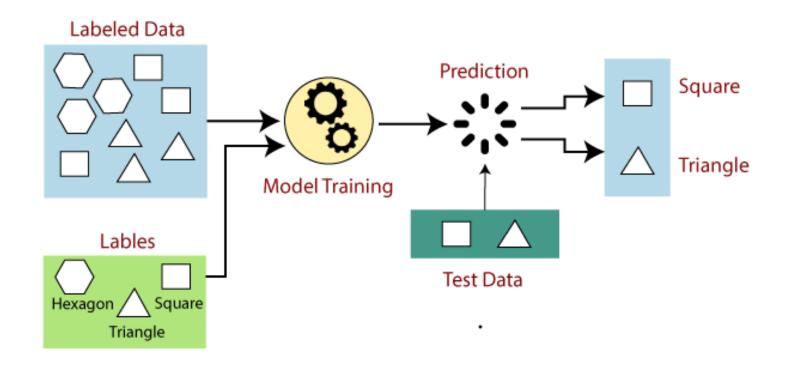
- annotazione e classi
- permette all'algoritmo di imparare a discernere un esempio dagli altri

#### • test set

- insieme di dati di *confronto*
- contiene informazioni del tutto simili al training set
- serve per *verificare* l'accuratezza dell'algoritmo addestrato



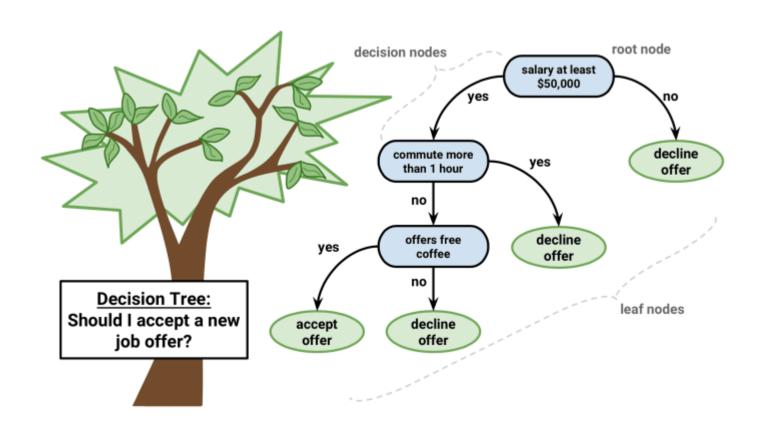
## supervised learning





## esempio di classificazione

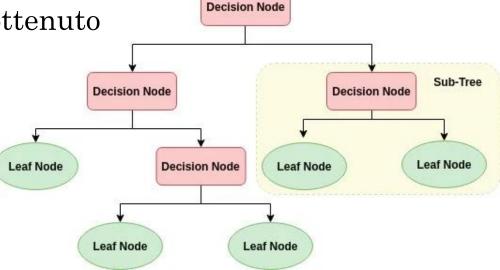
#### **Decision Tree Classifier**





### decision tree - albero decisionale

- è una struttura ad albero simile a un diagramma di flusso
- ogni un nodo interno rappresenta una feature (attributo)
- ogni ramo rappresenta una regola decisionale
- ogni nodo foglia rappresenta il risultato ottenuto





## unsupervised learning

apprendimento non supervisionato



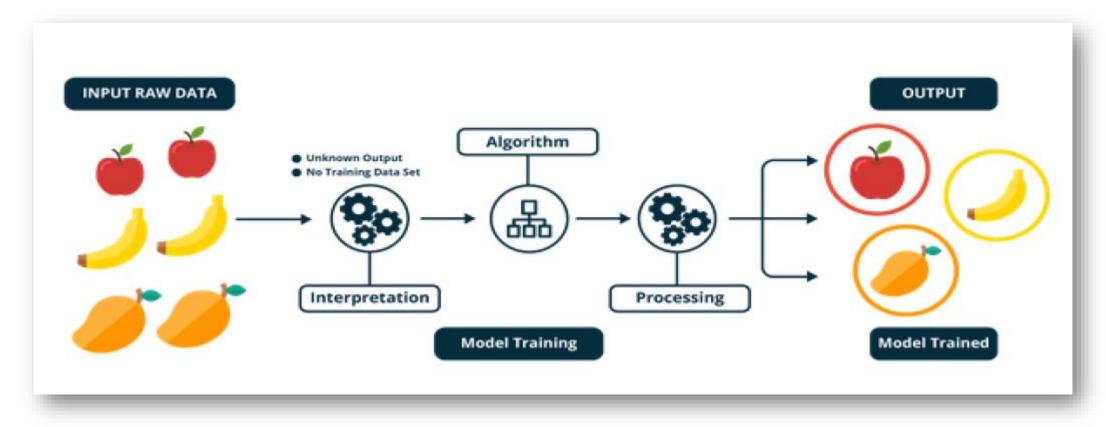
## unsupervised learning

- apprendimento *non supervisionato*
- consiste nel fornire al sistema informatico una serie di *input* (esperienza del sistema)
- il sistema *classifica* i dati sulla base di caratteristiche comuni
- lo scopo è cercare di effettuare ragionamenti e previsioni sugli input successivi
- durante la fase di apprendimento vengono forniti solo esempi non annotati
- le *classi non sono note a priori* ma devono essere apprese automaticamente

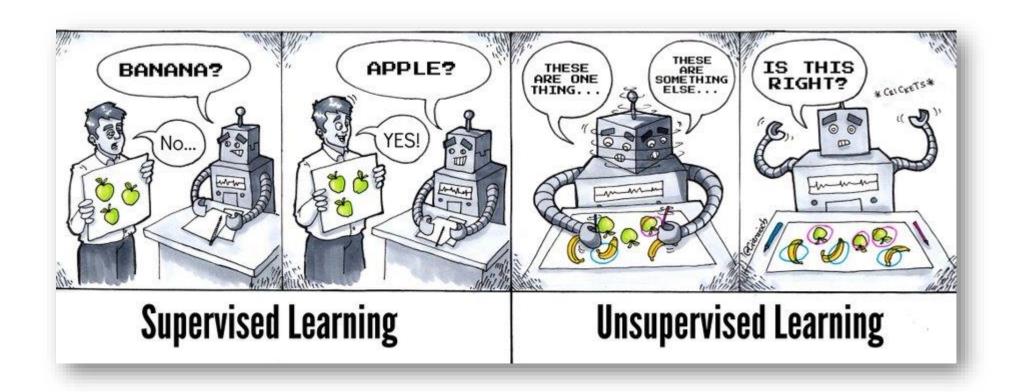


## unsupervised learning

• dati raw, no labels => il modello può raggruppare gli items per similitudine









## unsupervised learning - esempio

- esempio classico in ambito *marketing*
- i *consumatori* con caratteristiche simili vengono raggruppati (*classificati*) in base ai loro acquisti in categorie
- in base all'appartenenza alle varie categorie vengono attivate *campagne di marketing* specifiche





## semi-supervised learning

 $apprendimento\ semi-supervision ato$ 



## semi-supervised learning

- apprendimento semi-supervisionato
- combina una *grande* quantità di dati *non etichettati* con una *piccola* quantità di dati *etichettati*
- l'apprendimento non supervisionato insieme a quello supervisionato permette all'algoritmo di *suddividere in cluster* gli esempi e poi di assegnare a tutti gli elementi di un certo gruppo la *label* di quelli etichettati presenti nel gruppo

#### vantaggi

• permette il *labeling automatico* di grandi quantità di dati altrimenti non etichettabili

#### svantaggi

• i dati al confine fra due gruppi potrebbero avere etichette di entrambi introduce un po' di *bias* nel training



## tecniche di apprendimento automatico



## tipi di apprendimento automatico

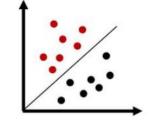
- $\cdot$  classificatione
- regressione
- clustering

#### Regression

- Predict continuous valued output
- Supervised

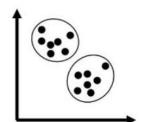
#### Classification

- Predict discrete valued output
- Supervised



#### Clustering

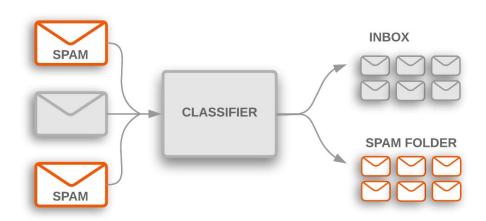
- Predict discrete valued output
- Unsupervised





## classificazione

- permette di *categorizzare* un insieme di dati in classi
- problemi affrontabili con algoritmi di classificazione sono
  - riconoscimento vocale
  - riconoscimento facciale
  - interpretazione della scrittura a mano
  - classificazione dei documenti
  - riconoscimento di immagini
  - ...





## matrice di confusione (confusion matrix)

- utilizzata per *valutare* un modello di machine learning
- è una matrice in cui
  - le *previsioni* sono rappresentate nelle righe
  - lo stato *effettivo* è rappresentato nelle colonne

	True Class		
	Apple	Orange	Mango
lass Apple	7	8	9
Predicted Class ngo Orange App	1	2	3
Prec Mango	3	2	1

#### **Confusion Matrix**

	Actually Positive (1)	Actually Negative (0)
Predicted Positive (1)	True Positives (TPs)	False Positives (FPs)
Predicted Negative (0)	False Negatives (FNs)	True Negatives (TNs)



## matrice di confusione - esempio con due classi (mail)

- true positive (TP veri positivi)
  - il modello ha classificato la mail come spam e lo è realmente
- *true negative* (TN veri negativi)
  - il modello ha classificato la mail come non spam e non lo è realmente
- false positive (FP falsi positivi)
  - il modello ha classificato la mail come spam ma in realtà non lo è
  - definito errore di primo tipo
- false negative (FN falsi negativi)
  - il modello ha classificato la mail come non spam ma in realtà si tratta di uno spam
  - definito errore di secondo tipo



#### metriche di valutazione

- *tasso di errore* (error rate) ERR
  - numero di tutti i pronostici errati diviso per il numero totale del set di dati
  - il miglior tasso di errore è 0, il peggiore è 1

$$ERR = \frac{FP + FN}{TN + FP + FN + TP}$$

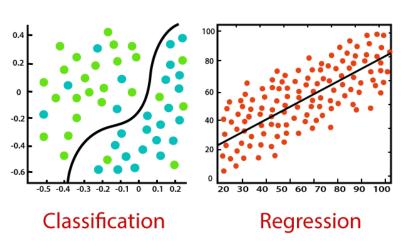
- accuratezza (accuracy)
  - la migliore accuratezza è 1, la peggiore è 0

$$Accuracy = \frac{TP + TN}{TN + FP + FN + TP}$$



## regressione

- modello di calcolo statistico che, a differenza della classificazione, non assegna una classe ad ogni item esaminato ma assegna un *valore reale stimato*
- il calcolo statistico è il risultato di un algoritmo di *minimizzazione di errore*
- la regressione fa sempre riferimento all'apprendimento *supervisionato*
- problemi affrontabili con algoritmi di classificazione
  - previsioni temperature meteo
  - previsioni andamento azioni di borsa
  - stima della capacità di spesa di clienti
  - ...



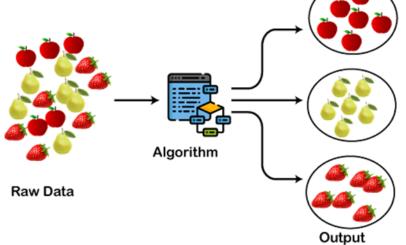


## clustering

- lo scopo è di *raggruppare* gli items analizzati in gruppi con *caratteristiche simili*
- il *calcolo* effettuato per determinare le similitudini fra items è spesso la *distanza* in qualche spazio n-dimensionale

• fa riferimento ad analisi di apprendimento *non supervisionato* 

• è di *supporto* in algoritmi semi-supervised

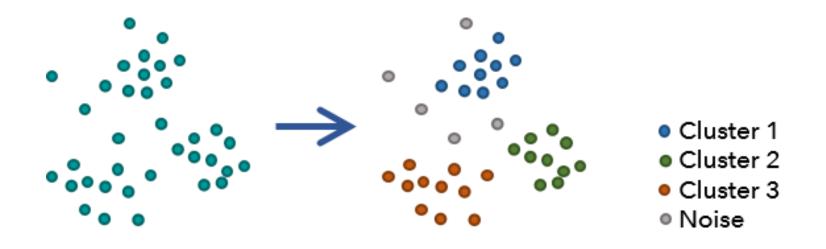




#### clustering

insieme di tecniche volte alla selezione e raggruppamento di elementi omogenei in un insieme di dati

le tecniche di clustering si basano su misure relative alla somiglianza tra gli elementi





#### bias

insieme di assunzioni che il classificatore usa per predire l'output dati gli input che esso non ha ancora incontrato

(Mitchell, 1980)

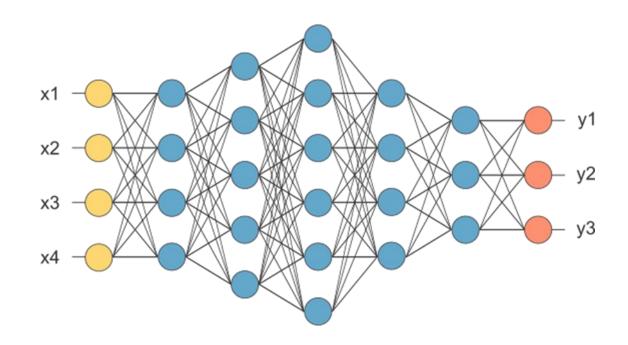




giudizi (o pregiudizi) che non corrispondono necessariamente alla realtà, sviluppati sulla base dell'interpretazione delle informazioni in possesso che portano a un errore di valutazione o mancanza di oggettività di giudizio



## reti neurali artificiali

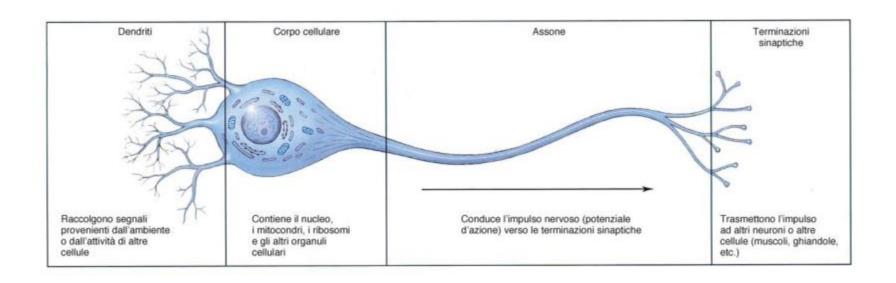




## reti neurali artificiali

- rete neurale artificiale
  - "... un sistema di elaborazione costituito da una serie di elementi di elaborazione semplici e altamente interconnessi, che elaborano le informazioni mediante la loro risposta di stato dinamica agli input esterni." (Robert Hecht-Nielsen)
- una rete neurale artificiale rappresenta un software che cerca di imitare come funziona il *cervello* umano
- gli elementi di elaborazione semplici e altamente interconnessi sono i neuroni (nodi)

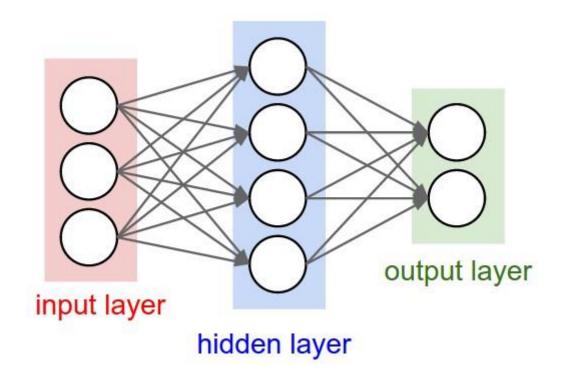






## tipi di nodi - livelli

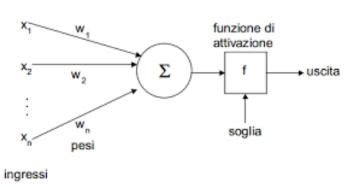
- input layer (livello di ingresso)
  - riceve le informazioni provenienti dall'esterno
- *hidden layer* (livello nascosto)
  - collega il livello di ingresso con quello di uscita e aiuta la rete neurale ad imparare le relazioni complesse
  - spesso i livelli nascosti sono più di uno
- output layer (livello di uscita)
  - mostra il risultato





## funzionamento

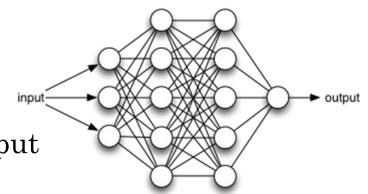
- ogni *livello* è formato da centinaia *neuroni* artificiali
- ogni neurone artificiale è connesso con neuroni di altri livelli
- ad ogni *connessione* è associato un *peso*
- i pesi iniziali sono impostati *casualmente*
- ad ogni neurone è associata una *funzione di attivazione* che dipende dai pesi delle connessioni in entrata
- la funzione determina l'attivazione o meno delle connessioni in uscita
- ogni serie di dati in ingresso attraversa tutti gli strati della rete e restituisce un output attraverso il livello di *uscita*





## apprendimento

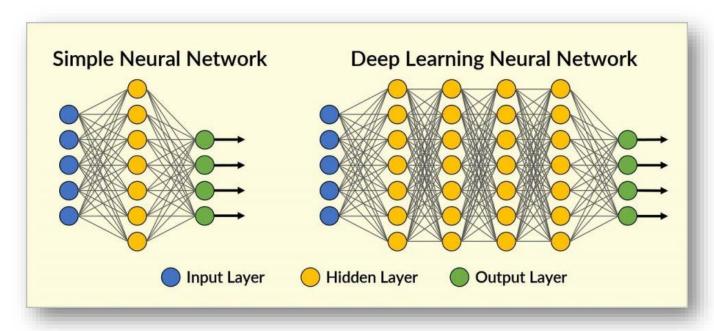
- feedback
  - verifica della risposta in output in base ai dati di input
- algoritmo di *backpropagation* 
  - *confronta* il risultato ottenuto da una rete con l'output che si vuole in realtà ottenere
  - la differenza tra i due risultati prevede di *modificare i pesi* delle connessioni tra i livelli della rete partendo dal livello output
  - procedendo a *ritroso* modifica i pesi dei livelli nascosti e quelli dei livelli di input





## deep learning

- si parla di deep learning quando una rete neurale artificiale che è composta da almeno 2 *livelli nascosti*
- le applicazioni di deep learning contengono normalmente *molti* più livelli nascosti (10, 20 o più)



Alberto Ferrari – Big Data

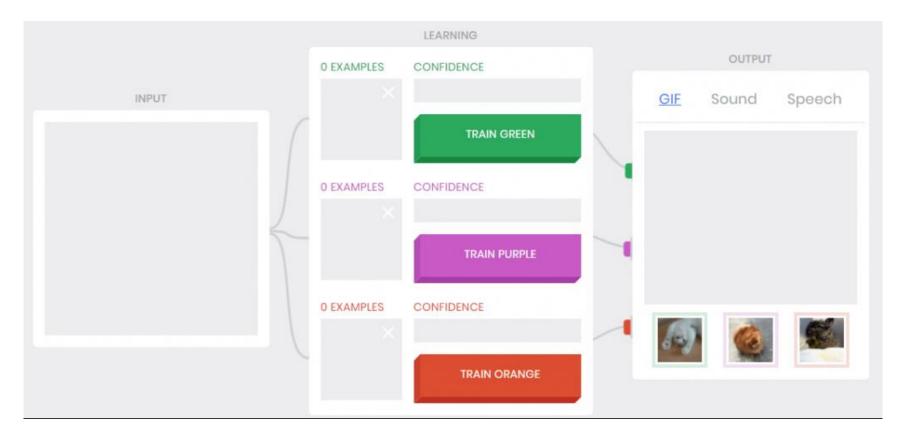


## applicazioni deep learning

- traduzione automatica
  - algoritmi di deep learning migliorano l'apprendimento delle relazioni tra parole e la loro mappatura in una nuova lingua
  - Google Neural Machine Translation
- classificazione di oggetti in immagini
  - algoritmi in grado di classificare gli oggetti di una immagine
- generazione automatica di *linguaggio naturale* 
  - applicazione che produce voce umana (es <u>Wavenet</u>)
- · lettura delle labbra
- colorazione automatica di immagini in bianco e nero



## https://www.youtube.com/watch?v=3BhkeY974Rg



https://teachablemachine.withgoogle.com/



### video

- · come funziona il machine learning
  - <a href="https://www.youtube.com/watch?v=f\_uwKZIAeM0">https://www.youtube.com/watch?v=f\_uwKZIAeM0</a>
- google immagini
  - <a href="https://www.youtube.com/watch?v=xkbBC9ZejI0&t=18s">https://www.youtube.com/watch?v=xkbBC9ZejI0&t=18s</a>
- applicazioni
  - <a href="https://youtu.be/UwsrzCVZAb8">https://youtu.be/UwsrzCVZAb8</a>
- test
  - <a href="https://teachablemachine.withgoogle.com">https://teachablemachine.withgoogle.com</a>